

geoTwitter to #Russia2018

Ricardo Garcia Ruiz

30 de junio, 2018

Contents

1	Práctica 1: Análisis de datos geoespaciales	1
1.1	Enunciado	1
2	Ejercicio 1: Análisis geocodificado de tweets	1
2.1	Desarrollo	1
2.2	Resolución Ejercicio 1	2
3	Ejercicio 2: Generación de mapas de contaminación	4
3.1	Desarrollo	4

1 Práctica 1: Análisis de datos geoespaciales

1.1 Enunciado

Este documento recoge la práctica de la asignatura “**Análisis de Datos Geoespaciales**”. Se plantean dos ejercicios independientes; ambos ejercicios deben resolverse de forma individual y autónoma por el estudiante. Para la resolución de los ejercicios podrán emplearse como apoyo los materiales del aula y contenidos de internet.

2 Ejercicio 1: Análisis geocodificado de tweets

El análisis geográfico de las aportaciones de usuarios de redes sociales como Twitter o Facebook ha ido ganando relevancia en los últimos años como herramienta para el estudio de fenómenos socioculturales. En el ejercicio se plantea el uso de la red social Twitter.

El objetivo del ejercicio es geocodificar, a nivel país, la procedencia de los usuarios que han utilizado un hashtag o etiqueta determinada (a elegir por el estudiante). A partir de los tweets individuales obtenidos de la red social, se propone la generación de un mapa que muestre el número de tweets por país. El mapa, tematizado convenientemente, será publicado en la aplicación GIS en la nube ArcGIS Online.

2.1 Desarrollo

Se propone al estudiante seleccionar un hashtag (por ejemplo “#Eurovision2018”) y realizar una búsqueda de tweets que contengan la etiqueta seleccionada. Para ello, se propone, en el Anexo I del presente documento, un método de geocodificación de los usuarios autores de los tweets. Una vez geocodificados los usuarios (a partir de la información de localización asociada a cada perfil de usuario), se realizará un análisis geográfico que contabilizará el número de usuarios por país. Se propone utilizar la misma capa (shapefile) de países que se empleó en la PEC1 y disponible en el aula (Fichero PAISES_GENERALIZADOS.rar). Todo éste proceso será desarrollado utilizando R.

El shapefile resultante de éste análisis se subirá a la plataforma ArcGIS Online y se tematizará convenientemente. Una vez finalizado, el mapa será compartido con el profesor (jde_diegoa@uoc.edu). Se incluirá

también la URL del mapa en el documento de entrega que se subirá al Registro de Evaluación Continua del Aula. Nota: Ha de tenerse en cuenta que en este ejercicio se utilizarán APIs de acceso gratuito pero limitado. Se busca que el estudiante obtenga al menos 500 resultados válidos geocodificados a nivel país (como mínimo).

2.2 Resolución Ejercicio 1

2.2.1 Carga de los elementos de acceso a Twitter

En primer lugar obtenemos las claves de acceso a Twitter según el manual de procedimiento de la práctica. Una vez adquiridas procedemos a cargarlas en variables en R para poder aplicarlas a una función de acceso a Twitter desde el entorno de RStudio:

```
# variables de acceso a Twitter mediante R a geoTwitterRussia2018
consumer_key <- "Djv1QIHp5DCTtFZDF4P7PmKhe"
consumer_secret <- "PXwhHVALeuGnH5Myn4qLzwfM0YUHCX67Ife8tlujhAGI0lwYe"
access_token <- "287839706-VlvixPev6CuRnMwAlNn5U7VeVEafgh3JMWCHqUvL"
access_secret <- "cSorAvqalS82yU2hhJj5pZvBHPNQt00Vd04ZV7gwJWTH"
```

Ahora procedemos a ajustar las funciones de handshake de autenticación OAuth del paquete httr para una sesión twitterR. Esto lo hacemos mediante la siguiente función de carga:

```
# Esta función ajusta las funciones de handshake de autenticación
# OAuth del paquete httr para una sesión twitterR
setup_twitter_oauth(consumer_key, consumer_secret, access_token, access_secret)
```

```
## [1] "Using direct authentication"
```

En el momento de ejecutar esta función se nos permite optar por ajuste del OAuth permanentemente o bien hacerlo por cada sesión. Nosotros optamos por el modo permanente.

2.2.2 Acceso a Twitter desde R para carga de twitts

A continuación, procedemos a delimitar el tipo de hashtag que vamos a utilizar. Aunque hemos estado dudando entre utilizar ‘#Russia2018’ o bien combinado con ‘#WorldCup’, finalmente optamos solo por la versión sencilla:

```
# Hashtag definitivo
searchTerm <- "#Russia2018"

# Número máximo de twitts
searchResults <- searchTwitter(searchTerm, n = 15000)
```

Además, como se ve, se pide la carga de 15000 twitts máximo.

A continuación convertimos la lista con los resultados obtenidos en un data.frame manejable en R:

```
# convierte la lista de resultados searchResult en un dataframe
tweetFrame <- twListToDF(searchResults)
```

Table 1: Detalle del dataframe tweetFrame

text	favorited	favoriteCount	replyToSN	created	truncated
Length:15000	Mode :logical	Min. : 0,000	Length:15000	Min. :2018-06-28 15:20:36	Mode :logical
Class :character	FALSE:15000	1st Qu.: 0,000	Class :character	1st Qu.:2018-06-28 17:38:44	FALSE:11157
Mode :character	NA	Median : 0,000	Mode :character	Median :2018-06-28 20:56:39	TRUE :3843
NA	NA	Mean : 1,421	NA	Mean :2018-06-29 01:08:13	NA

text	favorited	favoriteCount	replyToSN	created	truncated
NA	NA	3rd Qu.: 0,000	NA	3rd Qu.:2018-06-29 09:29:42	NA
NA	NA	Max. :2420,000	NA	Max. :2018-06-29 18:31:38	NA

Table 2: Detalle del dataframe tweetFrame

replyToUID	statusSource	screenName	retweetCount	isRetweet	retweeted	longitud
Length:15000	Length:15000	Length:15000	Min. : 0,0	Mode :logical	Mode :logical	Length:15000
Class :character	Class :character	Class :character	1st Qu.: 0,0	FALSE:7073	FALSE:15000	Class :character
Mode :character	Mode :character	Mode :character	Median : 2,0	TRUE :7927	NA	Mode :character
NA	NA	NA	Mean : 125,5	NA	NA	NA
NA	NA	NA	3rd Qu.: 39,0	NA	NA	NA
NA	NA	NA	Max. :23244,0	NA	NA	NA

En este momento generamos una lista de los usuarios que han emitido twits sobre los datos obtenidos en `tweetFrame`:

```
# lista (userInfo) a partir del listado de usuarios asociados a los tweets anteriores

# como calcularla completa da un error persistente se calcula por
# tramos y luego se une en una sola lista
userInfo <- lookupUsers(tweetFrame$screenName[1:5000])
userInfo2 <- lookupUsers(tweetFrame$screenName[5001:10000])

# Da error:
# Error in twInterfaceObj$doAPICall(paste("users", "lookup", sep = "/"), :
# Forbidden (HTTP 403).
#userInfo3 <- lookupUsers(tweetFrame$screenName[10001:15000])

userInfo3 <- lookupUsers(tweetFrame$screenName[10001:13900])
userInfo4 <- lookupUsers(tweetFrame$screenName[13450:15000])

# fusionamos los datos en una sola lista
userInfo = c(userInfo, userInfo2, userInfo3, userInfo4)

# borramos las variables no necesarias
rm(userInfo2, userInfo3, userInfo4)
```

Ahora pasamos a convertir esta lista en un dataframe que podamos utilizar con mayor comodidad en los cálculos posteriores:

```
# Convertimos la lista en dataframe
userFrame <- twListToDF(userInfo)
```

Table 3: Detalle del dataframe userFrame

description	statusesCount	followersCount	favoritesCount	friendsCount	url	na
Length:12117	Min. : 0	Min. : 0	Min. : 0	Min. : 0	Length:12117	Length:12117
Class :character	1st Qu.: 1298	1st Qu.: 113	1st Qu.: 242	1st Qu.: 170	Class :character	Class :character
Mode :character	Median : 5965	Median : 370	Median : 1424	Median : 440	Mode :character	Mode :character
NA	Mean : 27078	Mean : 11816	Mean : 10191	Mean : 1167	NA	NA
NA	3rd Qu.: 23036	3rd Qu.: 1253	3rd Qu.: 6745	3rd Qu.: 1022	NA	NA

description	statusesCount	followersCount	favoritesCount	friendsCount	url	na
NA	Max. :2187550	Max. :10865141	Max. :681598	Max. :245943	NA	

Table 4: Detalle del dataframe userFrame

protected	verified	screenName	location	lang	id	listedCou
Mode :logical FALSE:12108 TRUE :9 NA NA NA	Mode :logical FALSE:11745 TRUE :372 NA NA NA	Length:12117 Class :character Mode :character NA NA NA	Length:12117 Class :character Mode :character NA NA NA	Length:12117 Class :character Mode :character NA NA NA	Length:12117 Class :character Mode :character NA NA NA	Min. : 0. 1st Qu.: 0. Median : 5. Mean : 67. 3rd Qu.: 24. Max. :21506.

3 Ejercicio 2: Generación de mapas de contaminación

En los últimos años, la contaminación atmosférica se está convirtiendo en un grave problema en los entornos urbanos. En ciudades como Madrid, los altos niveles de contaminación están provocando un grave problema de salud pública. El Ayuntamiento de la ciudad ha decidido tomar una serie de polémicas medidas, que afectan sobre todo a la circulación de vehículos privados, con el fin de reducir la emisión de estos contaminantes y en especial del dióxido de nitrógeno (NO₂). El objetivo del ejercicio es la generación de dos mapas, uno utilizando el interpolador IDW y otro utilizando krigeaje, del máximo nivel de contaminación diaria para NO₂ en la ciudad de Madrid. Durante el ejercicio se utilizará R como entorno para el tratamiento de los datos.

3.1 Desarrollo

Para el desarrollo del ejercicio utilizaremos los siguientes conjuntos de datos: * Datos en tiempo real de calidad del aire: <https://goo.gl/BMLJ8X>. Utilizaremos el archivo etiquetado como “**Calidad del aire. Tiempo real csv**”. Tened en cuenta que este fichero se actualiza cada hora. La descripción del conjunto de datos puede encontrarse en <https://goo.gl/tBnK1o>.

- Estaciones de control: <https://goo.gl/AuCxvu>. Utilizaremos el fichero etiquetado como “**Calidad del aire: estaciones de control**”, en formato xls. Las coordenadas se encuentran codificadas como coordenadas geográficas sexagesimales, con datum de referencia WGS84.
- Límites geográficos de los distritos de Madrid: <https://goo.gl/SdZiH1>. Utilizaremos el fichero etiquetado como “**Distritos en formato geográfico en ETRS89**”. El fichero shapefile contiene los límites municipales en sistema de coordenadas EPSG:25830.

El procedimiento propuesto incluye los siguientes pasos:

- Descarga de la información indicada.
- Lectura de los ficheros de datos con R.
- Cálculo de las coordenadas geográficas de localización de las estaciones a partir de las coordenadas sexagesimales codificadas en los datos originales.
- Obtención del valor máximo horario de contaminación por NO₂ para cada estación (los datos de dióxido de nitrógeno vienen codificados con el valor 8 en el campo magnitud).
- Asociación de los datos de contaminación con la localización geográfica de cada estación.
- Reproyección de la capa de límites municipales y obtención de un polígono único con el límite del municipio.
- Elaboración de los mapas requeridos. En ambos casos se podrán utilizar diferentes juegos de parámetros.